

LAPORAN PRAKTIKUM 2: PRAPROSES DATA

Mata Kuliah: Praktikum Data Mining

Nama: Catherine Aprilia Harlina

NRP: 5054251012

1. Pendahuluan

Praproses data itu bisa dibilang tahap paling penting di data science buat ngolah raw data biar siap dipake sama model machine learning. Di praktikum kali ini, data yang dipake tuh dataset Kaggle House Prices (train.csv) yang isinya ada 1.460 baris data sama 81 kolom atribut.

2. Langkah-Langkah dan Hasil Praproses Data

2.1 Eksplorasi Data Awal

- **Langkah:** Pertama kita load dulu dataset-nya pke pandas, trs dicek struktur awalnya pke `.head()`, `.shape`, dan `.info()`
- **Hasil:** Datasetnya punya 1.460 baris sama 81 kolom. Pas dicek, ternyata lumayan banyak atribut yang punya missing values, baik yang tipe data numerik maupun kategorikal

2.2 Pembersihan Data (Data Cleaning)

1. **Penanganan Missing Values:**
 - **Drop Kolom > 50% Missing:** Atribut yang missing value-nya diatas 50% langsung kita drop aja (kek PoolQC, MiscFeature, Alley, dan Fence).
 - **Imputasi:** Buat sisa missing value yang numerik diisi pake nilai median, trs yang kategorikal diisi pake modus
2. **Hasil:** Sisa missing value di seluruh dataset udah beres semua alias jadi 0

2.3 Deteksi dan Penanganan Outlier

- **Langkah:** Kita deteksi outlier pake boxplot khusus di atribut numerik utama kek GrLivArea
- **Keputusan:** Outlier-nya ga kita hapus, tapi kita sesuaikan pke teknik capping atau IQR Windsorization di batas bawah ($Q1 - 1.5 \times IQR$) sama batas atas ($Q3 + 1.5 \times IQR$)
- **Alasan:** Soalnya kalo barisnya dihapus gitu aja, ntar kita kehilangan informasi penting dari variabel lainnya di rumah itu. Dadi pke capping biar nilainya tetep masuk akal tanpa harus membuang data

2.4 Transformasi Data


1. **Categorical Encoding:** Ubah kolom kategorikal jadi numerik pake One-Hot Encoding (`pd.get_dummies` plus `drop_first=True`) biar ga kena jebakan dummy variable trap
2. **Feature Scaling:** Melakukan Standarisasi (`StandardScaler`) ke atribut numerik biar rerata-nya ($\mu = 0$) dan standar deviasi-nya ($\sigma = 1$), kecuali kolom SalePrice sama Id

2.5 Reduksi Dimensi

1. **Eliminasi Korelasi Tinggi:** Cek matriks korelasi trs buang atribut yang nilainya diatas 0.85 biar ga redundan

2. **Principal Component Analysis (PCA):** Pake PCA buat compress data tapi tetep keep 90% variansi-nya ($n_components=0.90$)
3. **Hasil:** Kolom hasil encoding yang tadinya ratusan berhasil dipangkas jadi jauh lebih dikit pke Principal Components (PC) tanpa bikin informasi pentingnya ilang

3. Visualisasi



4. Ringkasan Dataset Akhir

Ini perbandingan ringkas dataset sebelum vs sesudah dipraproses:

Parameter Evaluasi	Dataset Awal (train.csv)	Dataset Akhir (df_pca / df_clean)
Jumlah Baris	1.460	1.460 (Aman gaada yang kebuang)
Jumlah Kolom	81	Udah dipangkas pke PCA (90% variansi)
Missing Values	Masih banyak yang kosong	0 (Udah diisi penuh)
Skala Fitur Numerik	Beda-beda jauh	Terstandarisasi ($\mu = 0, \sigma = 1$)
Format Teks	Masih bentuk string/object	Udah ke-encode numerik

5. Kesimpulan

Semua alur praproses dari loading, ngatasin missing value, benerin outlier pke capping, encoding, scaling, sampe reduksi dimensi pke PCA udah kelar semua. Data akhirnya sekarang udah bersih, skalanya dapet, dan udah ready banget buat dipakai masuk ke tahap pemodelan.