

LAPORAN PRAKTIKUM 2: PRAPROSES DATA

Mata Kuliah: Praktikum Data Mining

Nama: Catherine Aprilia Harlina

NRP: 5054251012

1. Pendahuluan

Praproses data (data preprocessing) merupakan tahapan krusial dalam alur kerja data science untuk mengubah data mentah (raw data) menjadi format yang bersih, terstruktur, dan siap digunakan oleh algoritma machine learning. Pada praktikum ini, praproses dilakukan pada dataset **Kaggle House Prices** (train.csv) yang terdiri dari 1.460 baris sampel dan 81 kolom atribut.

2. Langkah-Langkah dan Hasil Praproses Data

2.1 Eksplorasi Data Awal

- **Langkah:** Memuat dataset menggunakan pustaka pandas serta memeriksa struktur awal melalui perintah `.head()`, `.shape`, dan `.info()`.
- **Hasil:** Dataset awal memiliki **1.460 baris** dan **81 kolom**. Ditemukan beberapa atribut yang memiliki banyak nilai hilang (missing values), baik tipe data numerik maupun kategorikal.

2.2 Pembersihan Data (Data Cleaning)

1. Penanganan Missing Values:

- **Drop Kolom > 50% Missing:** Atribut dengan proporsi nilai hilang lebih dari 50% diidentifikasi dan dihapus (seperti PoolQC, MiscFeature, Alley, dan Fence).
- **Imputasi:** Sisa missing values pada atribut numerik diimputasi menggunakan nilai **median**, sedangkan atribut kategorikal diimputasi menggunakan nilai **modus**.

2. **Hasil:** Jumlah missing value pada seluruh dataset berkurang menjadi **0**.

2.3 Deteksi dan Penanganan Outlier

- **Langkah:** Menggunakan visualisasi boxplot untuk mendeteksi pencilan (outlier) pada atribut numerik utama seperti GrLivArea.
- **Keputusan Penanganan:** Outlier **tidak dihapus**, melainkan disesuaikan (capping/IQR Winsorization) pada batas bawah ($Q1 - 1.5 \times IQR$) dan batas atas ($Q3 + 1.5 \times IQR$).
- **Alasan:** Menghapus baris sampel pada dataset harga rumah akan mengurangi informasi berharga dari atribut lain. Capping menjaga variabilitas data tetap stabil tanpa membuang sampel data.


2.4 Transformasi Data

1. **Categorical Encoding:** Mengubah variabel kategorikal menjadi numerik menggunakan **One-Hot Encoding** (`pd.get_dummies` dengan `drop_first=True`) untuk mencegah korelasi sempurna (dummy variable trap).
2. **Feature Scaling:** Melakukan **Standarisasi** (`StandardScaler`) pada seluruh atribut numerik agar memiliki rerata ($\mu = 0$) dan standar deviasi ($\sigma = 1$), mengecualikan atribut target `SalePrice` dan `Id`.

2.5 Reduksi Dimensi

1. **Eliminasi Korelasi Tinggi:** Menghitung matriks korelasi dan menghapus atribut dengan korelasi antar-fitur di atas **0.85** untuk menghilangkan redundansi data.
2. **Principal Component Analysis (PCA):** Menerapkan PCA dengan ambang batas akumulasi variansi sebesar **90%** (`n_components=0.90`).
3. **Hasil:** Dimensi data hasil One-Hot Encoding yang awalnya berjumlah ratusan kolom berhasil dipangkas secara signifikan menjadi puluhan Principal Components (PC) utama tanpa kehilangan informasi penting.

3. Visualisasi



4. Ringkasan Dataset Akhir

Berikut adalah perbandingan ringkas kondisi dataset sebelum dan sesudah tahap praproses data:

Parameter Evaluasi	Dataset Awal (train.csv)	Dataset Akhir (df_pca / df_clean)
Jumlah Baris	1.460	1.460 (Utuh, tanpa baris terbuang)
Jumlah Kolom/Fitur	81	Reduksi PCA (90% Variansi terjaga)

Missing Values	Terdapat pada banyak atribut	0 (Telah diimputasi penuh)
Skala Fitur Numerik	Bervariasi (Ribuan - Puluhan)	Terstandarisasi ($\mu = 0, \sigma = 1$)
Format Fitur Text	Teks / Object	Ter-encode numerik penuh

4. Kesimpulan

Seluruh tahapan praproses data mulai dari loading, pembersihan missing value, penanganan outlier via capping, encoding, scaling, hingga reduksi dimensi menggunakan PCA telah berhasil dijalankan. Dataset akhir kini dalam kondisi bersih, seimbang secara skala, dan bebas dari multikolinearitas sehingga siap digunakan untuk pemodelan Machine Learning lanjutan.