

LAPORAN ANALISIS EKSPLORASI DATA (EDA)

tugas praktikum 1: scraping & eksplorasi data

nama: catherine aprilia harlina

nrp: 5054251012

mata kuliah: data mining

prodi: rekayasa kecerdasan artifisial

1. deskripsi dataset

dataset yang digunakan diperoleh lewat proses scraping data mentah e-commerce berupa katalog buku dengan jumlah total 1.650 baris dan 6 atribut (kolom).

tipe atribut dataset:

- *title (nominal): judul unik dari setiap buku (teks).*
- *category (nominal): kategori genre buku (contoh: fiction, business, arts & design).*
- *price_usd (numerik kontinu): harga buku dalam currency usd.*
- *rating (ordinal): tingkat penilaian pelanggan dengan skala kategorikal terurut (one, two, three, four, five).*
- *stock_status (nominal): status ketersediaan stok (in stock / out of stock).*
- *num_reviews (numerik diskrit): jumlah ulasan yang diberikan oleh pembeli (angka bulat).*

2. statistik deskriptif & kualitas data

dari hasil perhitungan statistik awal terhadap data mentah:

- *harga (price_usd): rata-rata harga buku sebesar \$47.35, dengan median \$37.65 dan rentang nilai dari \$7.22 hingga nilai maksimum \$543.96.*
- *ulasan (num_reviews): rata-rata jumlah ulasan adalah 44.82 (median 45 ulasan) dengan sebaran terendah 0 hingga tertinggi 71 ulasan.*
- *distribusi kategorikal: kategori buku terbanyak diwakili oleh fiction (241 buku) dan arts & design (234 buku). sebagian besar rating pelanggan berada pada tingkat four (552 buku) dan mayoritas produk berstatus in stock (1.449 buku).*

3. penanganan data (missing values & outliers)

→ *nilai yang hilang (missing values):*

- *kolom category memiliki 42 data hilang (2.55%). penanganan dilakukan dengan melakukan imputation nilai pengganti berupa 'unknown'.*
- *kolom price_usd memiliki 55 data hilang (3.33%). penanganan dilakukan dengan mengisi nilai kosong menggunakan nilai tengah (median) yaitu \$37.65 agar tidak terpengaruh oleh ekstremitas data.*

→ *deteksi outlier:*

menggunakan metode interquartile range (iqr) pada atribut price_usd (batas bawah: -\$15.25, batas atas: \$94.13), terdeteksi 63 data outlier (3.82%) dengan rentang harga tinggi di atas \$100. outlier ini tetap dipertahankan karena merepresentasikan produk buku kategori premium/collector editiony

4. visualisasi data & interpretasi

(grafik grid yang dihasilkan dari notebook di sini)

- *distribusi harga (histogram): bentuk grafik menunjukkan pola right-skewed (menceng ke kanan), di mana konsentrasi harga buku terbanyak berada pada rentang \$20 – \$80.*
- *buku per kategori (bar chart): distribusi jumlah buku antar kategori tergolong lumayan merata, dengan kategori fiction dan business menduduki urutan teratas.*
- *harga vs rating (boxplot): nilai median harga buku relatif stabil di semua tingkatan rating (one hingga five). hal ini mengindikasikan bahwa harga produk tidak secara langsung menentukan kepuasan/rating dari pembeli.*
- *jumlah ulasan vs harga (scatter plot): sebaran titik tidak menunjukkan adanya pola korelasi linier antara jumlah ulasan dan harga buku. buku dengan status in stock tersebar merata di seluruh tingkatan ulasan maupun harga.*