

LAPORAN ANALISIS EKSPLORASI DATA (EDA)

tugas praktikum 1: scraping & eksplorasi data

nama: catherine aprilia harlina

nrp: 5054251012

mata kuliah: data mining

prodi: rekayasa kecerdasan artifisial

1. Deskripsi Dataset

dataset ini ditarik lewat proses web scraping pd situs Books to Scrape (<https://books.toscrape.com/>) yang diproses scr otomatis mencakup 50 halaman katalog total data berhasil ditarik sebanyak 1.000 baris tanpa ada missing record sma sekali

struktur atribut yang ada di dataset beserta tipe datanya:

- judul (nominal): nama atau judul lengkap dr buku berupa teks
- harga_gbp (numerik kontinu /rasio): nominal harga buku dlm mata uang Pounds (£)
- rating (ordinal / numerik diskrit): skala tingkatan evaluasi buku dr angka 1 ampe 5
- ketersediaan (nominal / biner): status stok barang di website yang mana seluruhnya berstatus In stock
- url (nominal): link tautan langsung ke halaman detail produk

2. Statistik Deskriptif

perhitungan statistik deskriptif dilakukan buat mahami distribusi angka dan frekuensi atribut kategorikal di dlm dataset:

Ringkasan Statistik Numerik

Atribut	Mean	Median	Mode	Std Dev	Min	Max
harga_gbp	£35.07	£35.98	£16.28	14.45	£10.00	£59.99
rating	2.92	3.00	1.00	1.43	1.00	5.00

- harga_gbp: memiliki rata2 sebesar £35.07 dengan rentang nilai paling murah di £10.00 dan paling mahal di £59.99 simpangan baku (std dev) sebesar 14.45 nunjukin variasi harga yang terdistribusi lebar dr batas bawah ampe batas atas
- rating: rata2 rating buku berada pada angka 2.92 dengan nilai tengah (median) di angka 3.00 nampilin kalo sebaran rating seimbang di seluruh skala

3. Frekuensi Atribut Kategorikal


- ketersediaan: seluruh 1.000 data buku (100%) memiliki status In stock
- Penanganan Data (Quality & Outlier Analysis)
- Identifikasi Nilai Hilang (Missing Values): pemeriksaan menggunakan fungsi `.isna().sum()` nunjukin bahwa 0 missing values di seluruh kolom (judul harga_gbp rating ketersediaan url) data dinilai utuh jd ga perlu dilakukan proses imputation atau penghapusan baris
- Deteksi & Penanganan Outlier: deteksi outlier dilakukan pada atribut numerik harga_gbp memakai metode Interquartile Range (IQR):
$$IQR = Q3 - Q1 = £47.50 - £22.50 = £25.00$$

> Batas Bawah (Lower Bound): $Q1 - (1.5 \times IQR) = 22.50 - 37.50 = -15.00$

> Batas Atas (Upper Bound): $Q3 + (1.5 \times IQR) = 47.50 + 37.50 = 85.00$

karena seluruh rentang harga buku berada pada rentang £10.00 hingga £59.99 gaada nilai yang berada di luar batas bawah (-£15.00) maupun batas atas (£85.00) hasil perhitungan mengonfirmasi 0 outlier jd gaada pemotongan data (data trimming) atau transformation yang perlu diterapkan

4. Visualisasi & Interpretasi Data



penjelasan visualisasi dr dataset Books to Scrape berdsarkan 4 plot utama:

- **Distribusi Harga Buku (£):** histogram + KDE melht penyebaran harga buku dr £10 ampe £60 yang mana polanya cenderung uniform distribution alias rata banget di setiap range harga gaada penumpukan ekstrem di harga murah atau mahal doang
- **Distribusi Rating Buku:** countplot nunjukin frekuensi buku dr rating 1 ampe 5 terbagi cukup merata di kisaran 180 - 220 buku /kategori rating rating 1 dikit lebih dominan tp overall tetep seimbang spreadnya
- **Hubungan Rating vs Harga (£):** scatter plot antara rating dan harga nampilin titik data yg tersebar lurus vertikal di tiap angka rating dr bawah ampe atas melht kalo gaada korelasi linier sma sekali antara harga buku sm rating yg didapat
- **Boxplot Harga Berdasarkan Rating:** melht interquartile range (IQR) dan nilai median harga di tiap rating ada di kisaran £35-£37 yang sejajar secara horizontal garis whisker batas atas (£60) dan bawah (£10) sama semua di tiap rating yang makin mertegaskan kalo gaada outlier dan harga barang emg terdistribusi acak tanpa ngaruh ke rating

5. Kesimpulan & Insight

- Karakteristik Data Synthetic: distribusi harga yang teratur secara uniform serta gak ditemukannya outlier maupun missing value makin mengonfirmasi kayya dataset pada Books to Scrape dirancang scr acak (synthetic dummy data) untuk keperluan edukasi scraping
- Independensi Fitur: variabel harga dan rating bersifat independen penuh besaran harga buku gak menjadi indikator penentu kualitas atau rating yang diterima buku tersebut